



Bases de Datos NoSQL

Gestión de Datos

Vicente Calisto Educación Profesional - Escuela de Ingeniería

El uso de apuntes de clases estará reservado para finalidades académicas. La reproducción total o parcial de los mismos por cualquier medio, así como su difusión y distribución a terceras personas no está permitida, salvo con autorización del autor.

Hasta ahora

- Bases de datos relacionales
- SQL



Bases de datos relacionales

- Muchas estructura (un esquema fijo)
- Muchas garantías (ACID)
- Generalmente centralizadas (viven en un servidor)



NoSQL

Término común para denominar bases de datos con:

- Menos restricciones que el modelo relacional
- Menos esquema
- Menos garantías de consistencia
- Más adecuadas para la distribución



NoSQL: ¿Por qué?

Sistemas de bases de datos relacionales no están pensadas para un entorno altamente distribuido

WWW, google, twitter, instagram, etc.



Sistemas distribuidos

Dos problemas fundamentales:

- 1. Datos no caben en un computador
- 2. Servidores pueden fallar



Datos no caben en un computador

Fragmentación de los datos

Ej: Usuarios de twitter





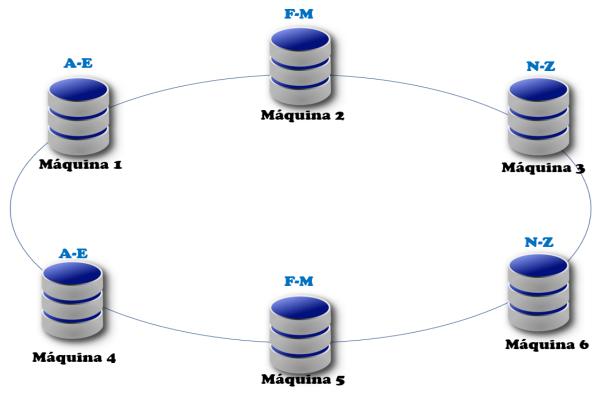


Fragmentación de relación **Usuarios** en tres



Servidores fallan

Replicación de los datos





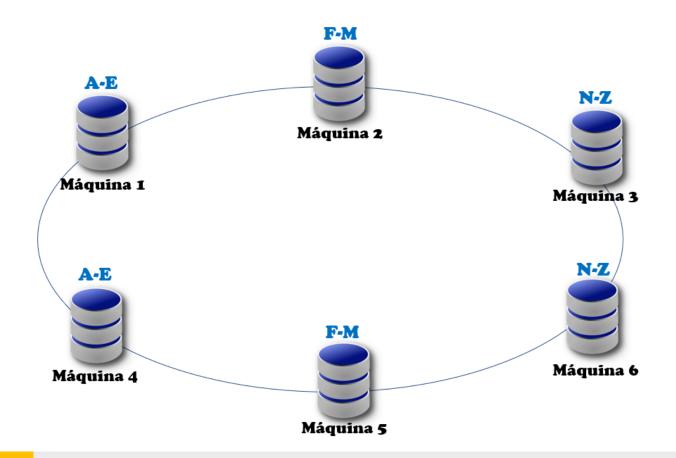
Replicación en un sistema distribuido

Garantías en un entorno distribuido

Tres propiedades fundamentales:

- Consistency (todos los usuarios ven lo mismo)
- Availability (todas las consultas siempre reciben una respuesta, aunque sea errónea)
- Partition tolerance (el sistema funciona bien pese a estar físicamente dividido)

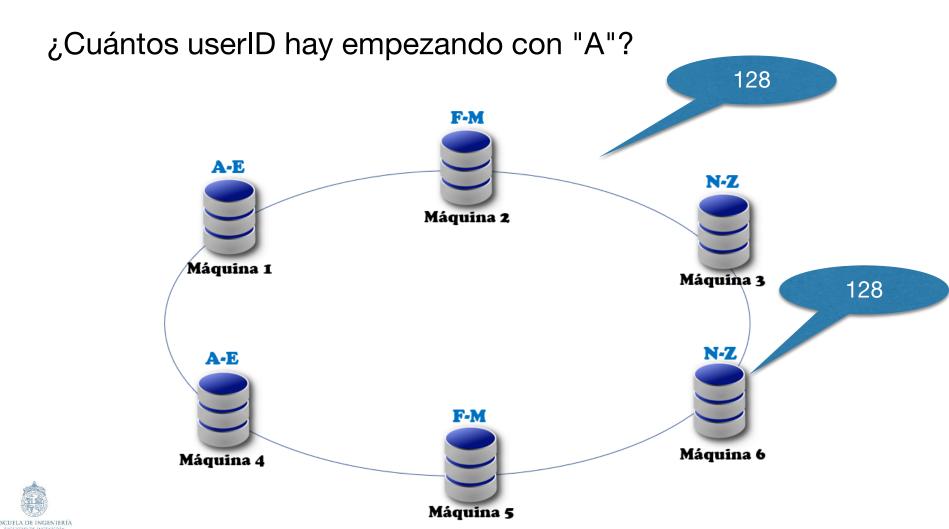




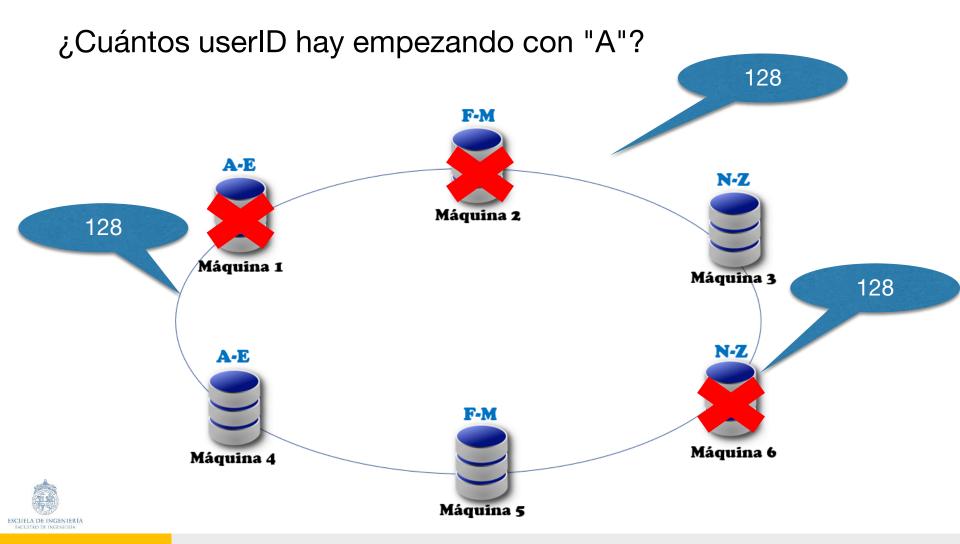


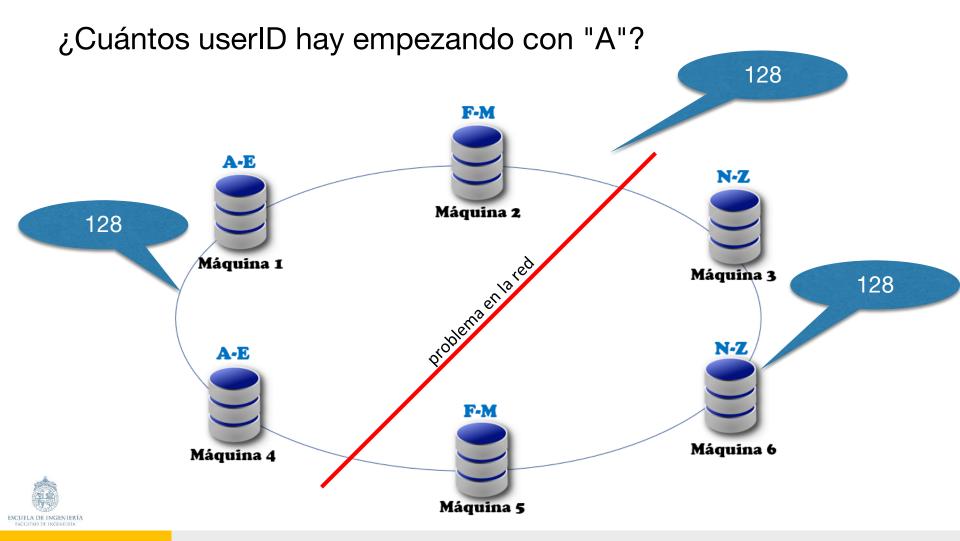
¿Cuántos userID hay empezando con "A"? 128 F-M A-E N-Z Máquina 2 Máquina 1 Máquina 3 N-Z A-E F-M Máquina 6 Máquina 4 Máquina 5



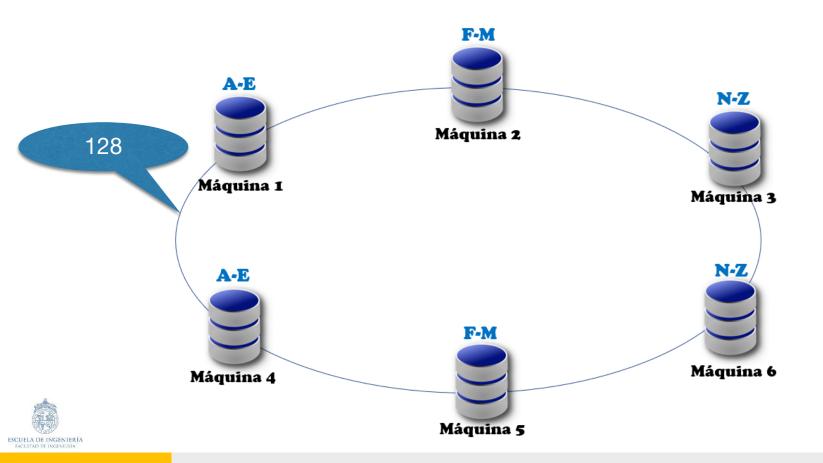




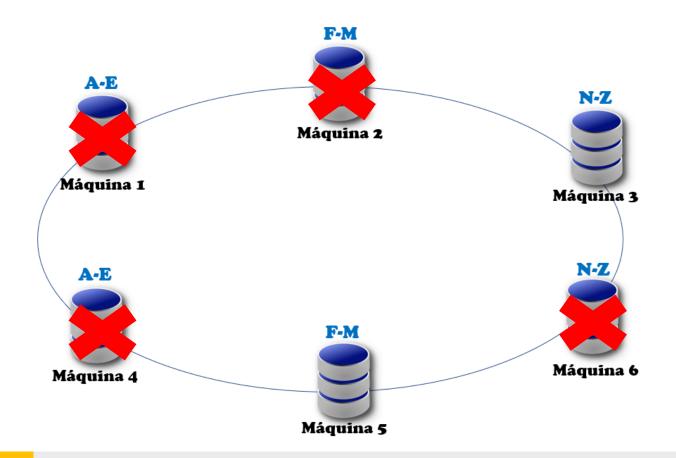




Availability

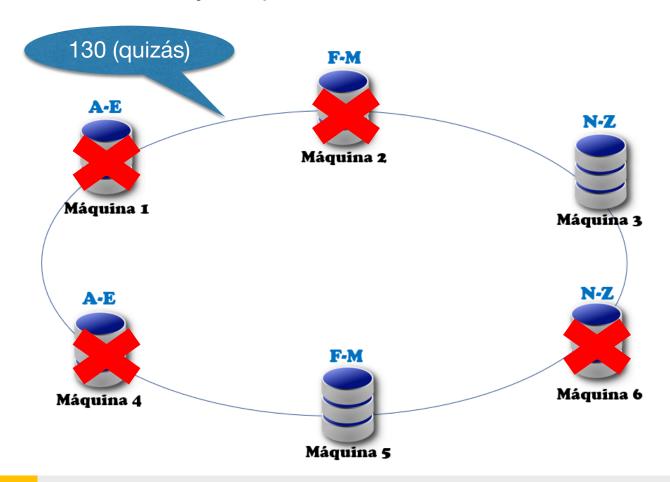


Availability



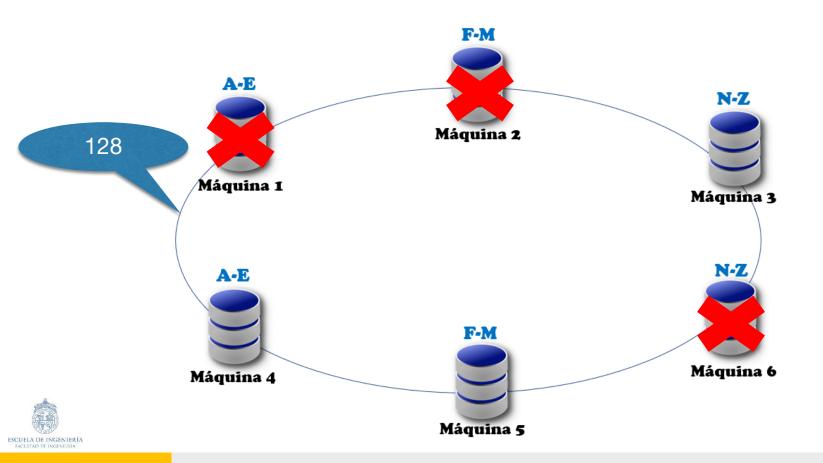


Availability

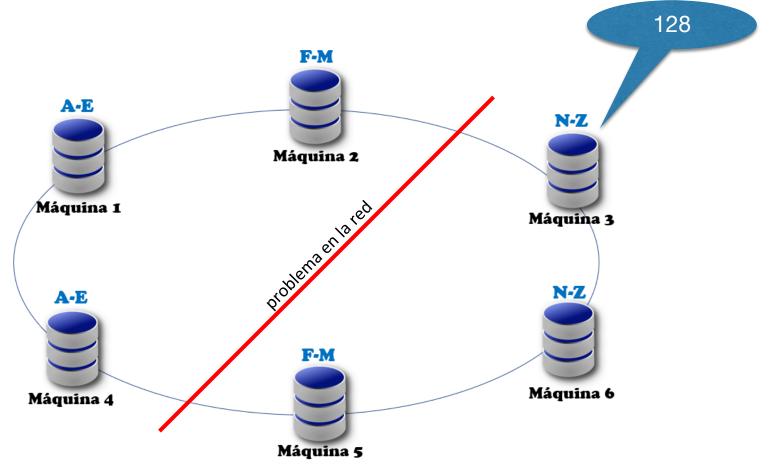




Partition tolerance



Partition tolerance





Teorema CAP

Plantea que para una base de datos distribuida es imposible mantener simultáneamente estas tres características:

- Consistency
- Availablity
- Partition tolerance



Teorema CAP

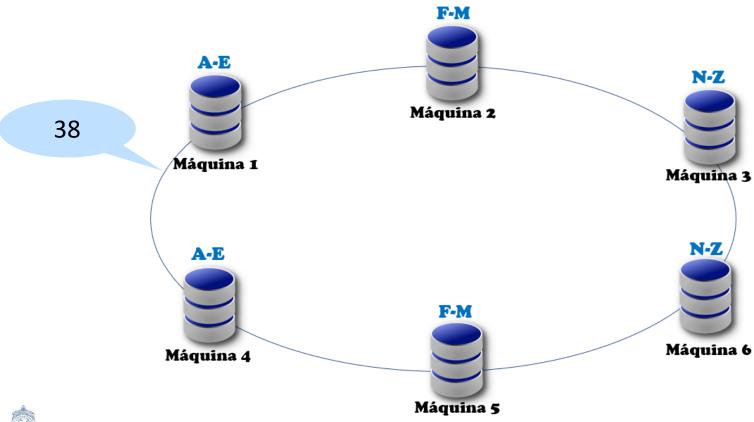
P es dado en cualquier sistema distribuido. Entonces, el Teorema CAP nos dice que hay que elegir entre:

- Consistency
- Availablity

Entonces tenemos sistemas CP y AP

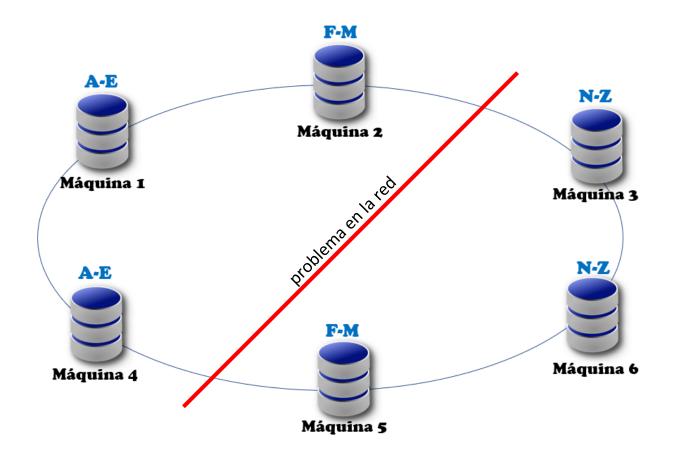


AP vs CP



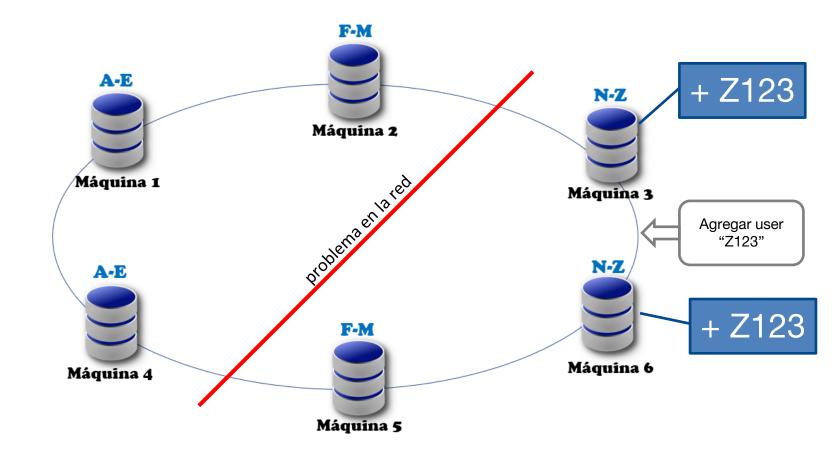


AP vs CP



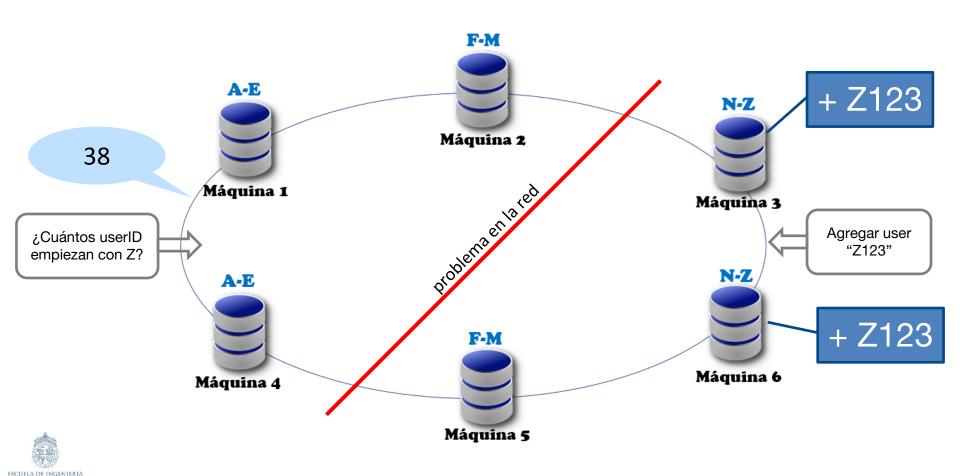


AP vs CP

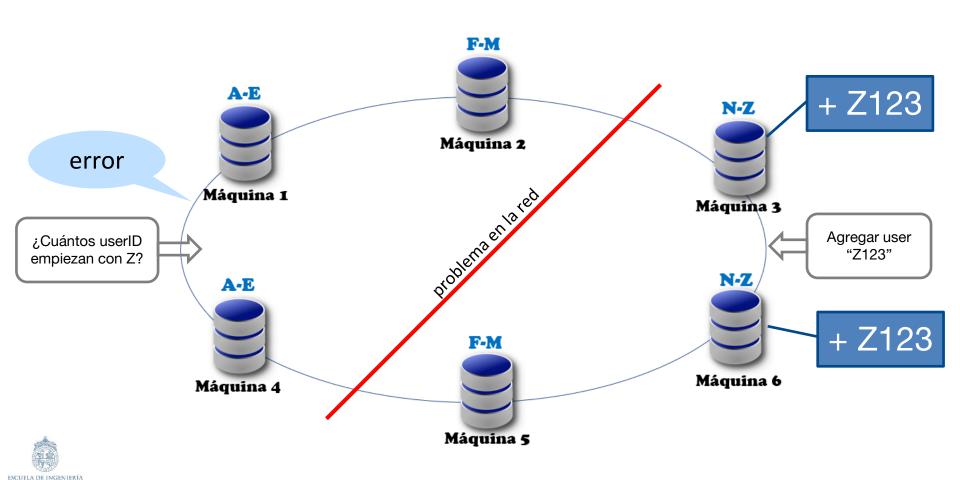




Un sistema AP



Un sistema CP



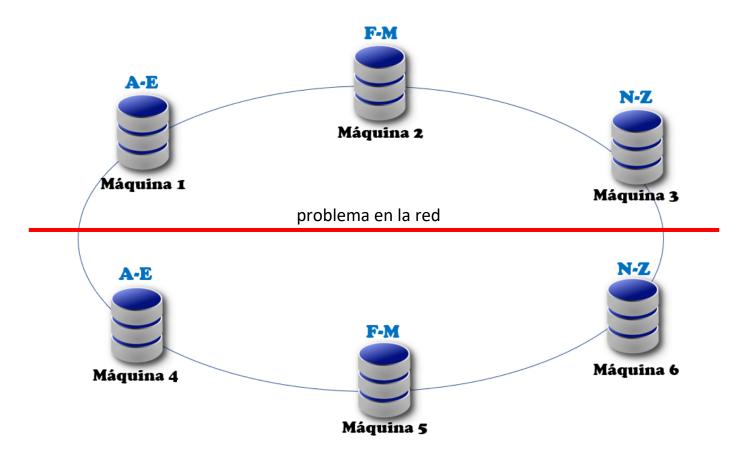
BASE

En la práctica, sistemas distribuidos fijan el P, y balancean entre C y A, sin elegir uno exclusivamente.

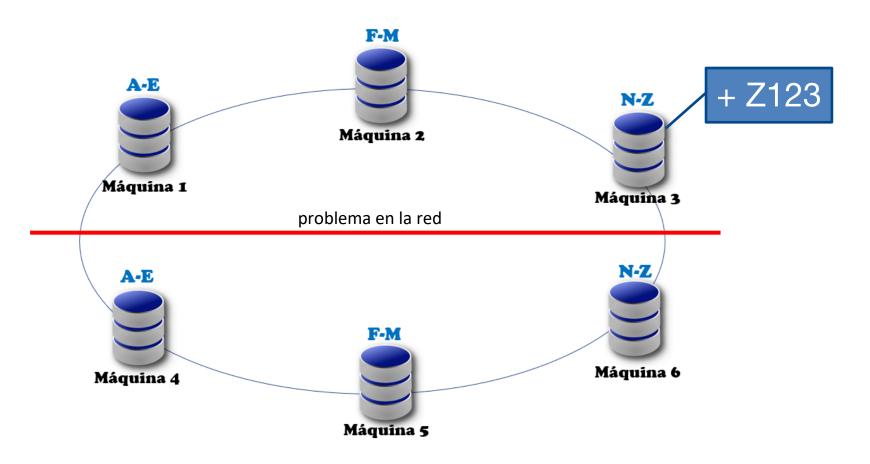
Paradigma BASE:

- Basically Available
- Soft state
- Eventually consistent

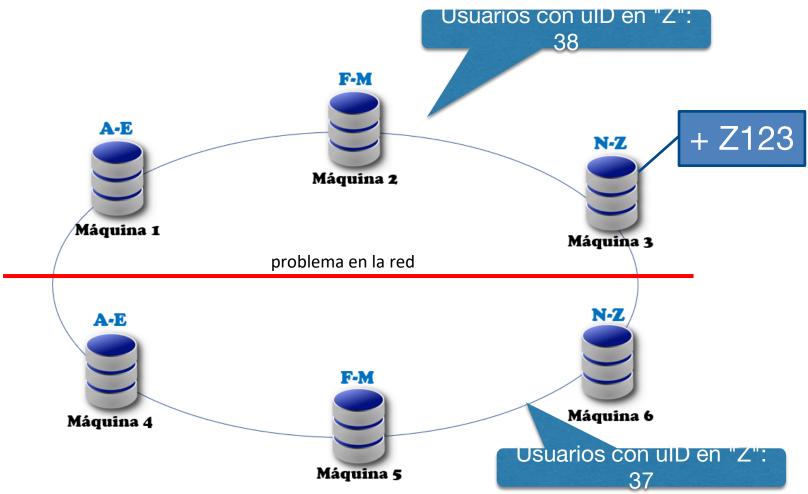




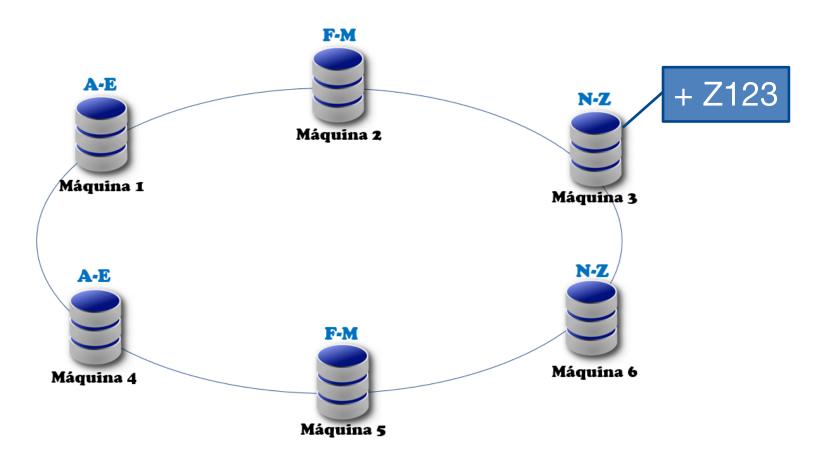




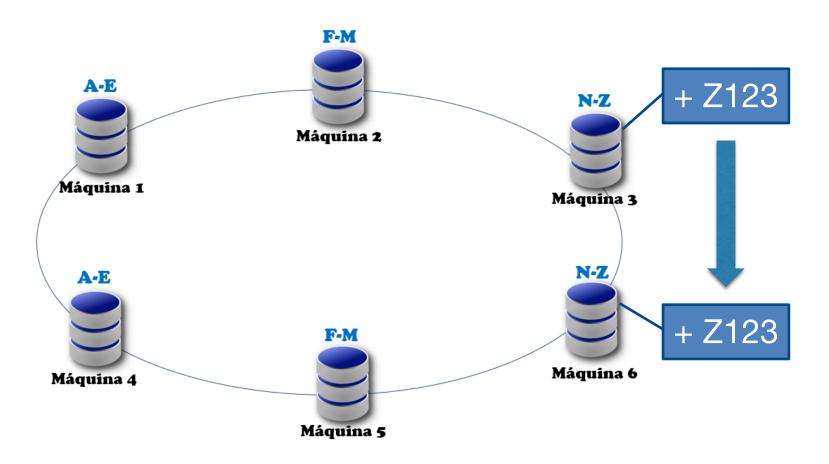




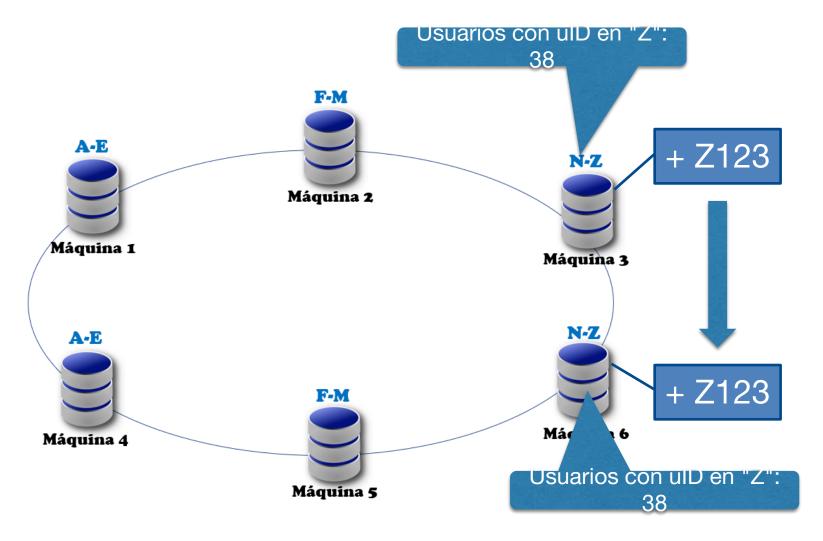














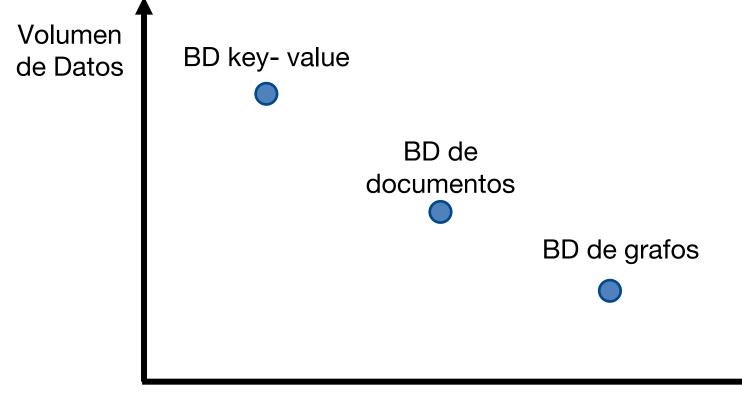
Sabores de NoSQL

Los más populares hoy en día:

- BD key-value
- BD de grafos
- BD de documentos



Sabores de NoSQL







Independientemente del esquema

- Arquitectura almacena información por medio de pares
- Cada par tiene una llave (identificador) y un valor



Operaciones cruciales:

- put(key,value)
- get(key)
- delete(key)

Key	Value
Chile	Santiago
Inglaterra	Londres
Escocia	Edinburgo
Francia	Paris
Alemania	Berlin
•••	•••



- Son grandes tablas de hash persistentes
- Esta categoría es difusa, pues muchas de las aplicaciones de otros tipos de BD usan key - value y hashing hasta cierto punto

Ejemplo más importante: Amazon Dynamo, otro es Redis



Puede representar cualquier valor

cartID	value
11789	usrID: "Juan", ítem: "Magic the Gathering Deck", value:
12309	usrID: "Domagoj", item: "APEX XTX50 regulator set", value:



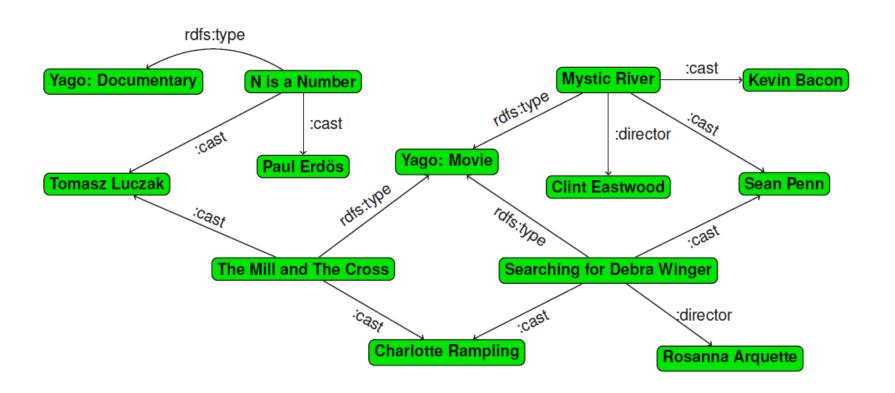
BD de Grafos y RDF

Especializadas para guardar relaciones

- En general, almacenan sus datos como property graphs
- Algunos ejemplos son Neo4J, Virtuoso, Jena, Blazegraph

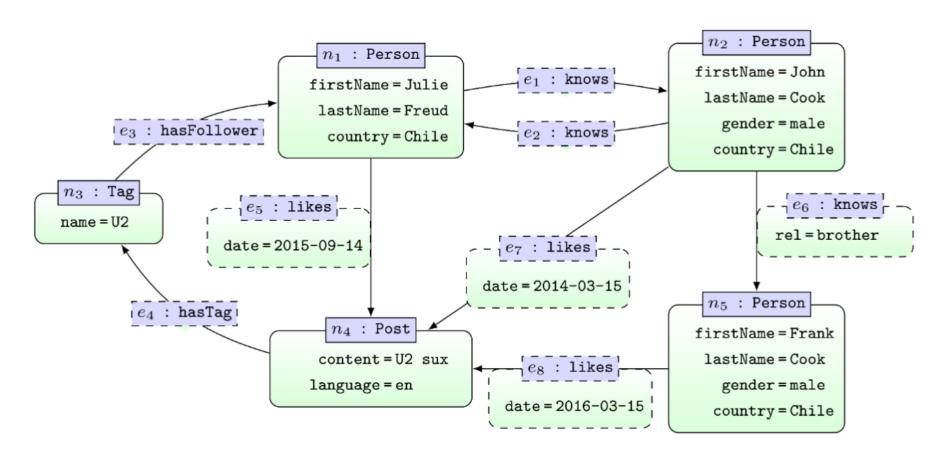


BD de Grafos y RDF





BD de Grafos y RDF





BD Orientadas a Documentos

Especializadas en documentos

- CouchDB, MongoDB (estas y otras BD almacenan sus datos en documentos JSON)
- JSON no es el único estándar de documentos (por ejemplo, existe también XML)



BD Orientadas a Documentos

Parecidas a key-value stores:

- El valor es ahora un documento (JSON)
- Pueden agrupar documentos (colecciones)
- Lenguaje de consultas mucho más poderoso



BD Orientadas a Documentos

Usuarios	
Key	JSON
1	<pre>"uid": 1, "name": "Adrian", "last_name": "Soto", "ocupation": "Delantero de Cobreloa", "follows": [2,3], "age": 24 }</pre>
2	



JSON

Su nombre viene de JavaScript Object Notation

Estándar de intercambio de datos semiestructurados / datos en la Web

JSON se acopla muy bien a los lenguajes de programación



JSON Ejemplo

```
"statuses": [
    "id": 725459373623906304,
    "text": "@visitlondon: Have you been to any of these
             quirky London museums? https://t.co/tnrar8UttZ",
    "retweeted_status": {
      "metadata": {
        "result_type": "recent",
        "iso_language_code": "en"
      },
      "retweet_count": 239,
      "retweeted": false
```



JSON

La base son los pares key - value

Valores pueden ser:

- Números
- Strings (entre comillas)
- Valores booleanos
- Arreglos (por definir)
- Objetos (por definir)
- null

JSON Sintaxis

Los objetos se escriben entre {} y contienen una cantidad arbitraria de pares key - value

```
{
    <mark>"nombre": "Matías", "apellido": "</mark>Jünemann"
}
```



JSON Sintaxis

Los arreglos se escriben entre [] y contienen valores



JSON vs SQL

SQL:

- Esquema de datos
- Lenguajes de consulta independientes del código

JSON:

- Más flexible, no hay que respetar necesariamente un esquema
- Más tipos de datos (como arreglos)
- Human Readable



BD de documentos: ¿para qué?

Especializadas en documentos: almacenan muchos documentos JSON

- Si quiero libros: un documento JSON por libro
- Si quiero personas: un documento JSON por persona

Notar que esto es altamente jerárquico



Qué hacen bien:

- Si quiero un libro o persona en particular
- Cruce de información simple

Muy útiles a la hora de desplegar información en la web



Pueden verse como un caché de una BD relacional ¿Por qué?



Students

StudentID	Nombre	Carrera
1	Alice Cooper	Computación
2	David Bowie	Todas
3	Charly García	Ingeniería Civil
	•••	

Courses

courseID	name	year
IIC2413	Databases	2020
IMT3830	Game Theory	2020

Takes

courseID	StudentID
IIC2413	1
IIC2413	2
IMT3830	2
NGI	

Lista de alumnos por curso:

- SQL tiene que hacer un join
- En BD documentos prepararemos esta información



Colección "Courses"

```
"courseID": IIC2413,
"name": "Databases",
"year": 2020,
"students":[
        "studentID": 1,
        "name": "Alice Cooper"
    },
        "studentID": 2,
        "name": "David Bowie"
    },
```



Colección "Courses"

```
"courseID": IIC2413,
"name": "Databases",
"year": 2020,
"students":[
        "studentID": 1,
        "name": "Alice Cooper"
    },
        "studentID": 2,
        "name": "David Bowie"
    },
```

```
"courseID": IMT3830,
"name": "Game Theory",
"year": 2020,
"students":[
        "studentID": 2,
        "name": "David Bowie"
        "studentID": 3,
        "name": "Charly García"
    },
```



Qué hacen bien:

- Si quiero lista de alumnos de un curso
- Si quiero nombres de todos los cursos
- Si quiero todo los cursos tomados por David

Muy útiles a la hora de desplegar información en la web



Qué hacen mal:

- Manejo de información que cambia mucho
- · Cruce de información no trivial



Colección "Courses"

Todos los alumnos que toman IIC2413 y IMT3830

```
"courseID": IIC2413,
"name": "Databases",
"year": 2020,
"students":[
        "studentID": 1,
        "name": "Alice Cooper"
        "studentID": 2,
        "name": "David Bowie"
```

```
"courseID": IMT3830,
"name": "Game Theory",
"year": 2020,
"students":[
        "studentID": 2,
        "name": "David Bowie"
        "studentID": 3,
        "name": "Charly García"
```



Colección "Courses"

Todos los alumnos que toman IIC2413 y IMT3830

Efectivamente hay que hacer un nested loop join:

- Iterar por todos los alumnos de IMT3830
- Iterar por todos los alumnos de IIC2413
- Ver si hacen el join

MongoDB soporta JavaScript y Python

Se puede hacer, pero no es elegante



En resumen

BD de documentos:

- Útiles para despliegue de información estática
- Búsquedas simples
- Cruces muy sencillos

BD SQL:

- Información cambia mucho
- Tengo que hacer cruces cada rato
- Necesito ACID



BD Documentos y BASE

- Distintas aplicaciones en una misma base de datos acceden a distintos documentos al mismo tiempo
- En general diseñadas para montar varias instancias que (en teoría) tienen la misma información
- Propagan updates en forma descoordinada

Proveen "Consistencia Eventual"



Consistencia Eventual

La consistencia eventual puede generar problemas

Si dos aplicaciones intentan acceder al mismo documento en MongoDB, estas pueden ser versiones diferentes del documento



Usuarios JSON Key "_id": ObjectId('60bfd90e002ce228636e506b'), "uid": 1, "name": "Adrian", 60bfd90e002ce228636e506b "last_name": "Soto", "ocupation": "Delantero de Cobreloa", "follows": [2,3], "age": 24 60bfd90e002ce228636e5215



Colección: una agrupación de documentos similares

Usuarios

Key	JSON
60bfd90e002ce228636e506b	<pre>{ "_id": ObjectId('60bfd90e002ce228636e506b'), "uid": 1, "name": "Adrian", "last_name": "Soto", "ocupation": "Delantero de Cobreloa", "follows": [2,3], "age": 24 }</pre>
60bfd90e002ce228636e5215	
	•••



Base de Datos: contienen colecciones relacionadas

Usuarios	
Key	JSON
Mensajes	
Key	JSON
Likes	
Key	JSON



Mensajería

Compras

WikiData

Un servidor contiene varias bases de datos



Consultando a MongoDB

```
show dbs ... muestra bases de datos disponibles
use dbName ... ahora usamos base de datos dbName
show collections ... colecciones en nuestra base de datos
db.colName.find() ... todos los documentos en la colección colName
db.colName.find().pretty() ... pretty print
db.colName.find({"name": "Adrian"}) ... selección
db.colName.find({"age": {$gte:23}}) ... selección
db.colName.find({"age": {$gte:23}},{"name":1}) ... proyección
```



Text Search en MongoDB

Un índice especial ... permite búsqueda rápida de texto

db.colName.createIndex({"attributeName":"text"})

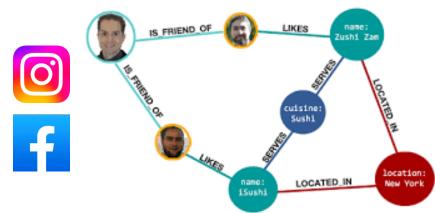
db.users.find({\$text: {\$search: "Delantero de Cobreloa"}})

Ver más en: https://www.youtube.com/watch?v=vR97-4UG7x0



Volviendo a los grafos...







elis silvestris catus

:ículo Discusión

Color = Longitude = Number of routes

GEOGRAPHICAL LAYOUT

MIDDLE

Leer Ver código fuente Ver historial Herramientas v

edirigido desde «Gato»)

«Gato» y «Gata» redirigen aquí. Para otras acepciones, véanse Gato (desambiguación) y Gata (desambiguación).

gato doméstico ¹ ² (*Felis silvestris catus*) llamado más comúnmente gato, y de ma coloquial minino, ³ michino, ⁴ y algunos nombres más, es un mamífero rnívoro de la familla *Felidae*.

El nombre actual en muchas lenguas proviene del latín vulgar catus.

Paradójicamente, catus aludía a los gatos salvajes, mientras que los gatos domésticos eran llamados felis.

de mutaciones genéticas, cruzamiento y selección artificial, hay s. Algunas, como la raza sphynx o la peterbald están desprovistas de en de cola, como los gatos de la raza bobtail o la manx, y algunas nes atípicas, como los llamados gatos azules.

nica a través de vocalizaciones. Las más populares son su aullido y el ronroneo, pero puede aullar, gemir, gruñir y bufar. ⁵ poses o expresiones que informan, a sus congéneres, sus enemigos s, de su ánimo o sus intenciones.

o, es el animal doméstico más popular como mascota, como ayuda a roedores o ambas cosas. En el 2017, la población mundial os estaba en seiscientos millones de felinos. En esta cifra se que son mascota, gatos callejeros (sin hogar) y gatos salvajes; s gatos silvestres alrededor de 100 millones. El país considerado que más felinos tiene como mascota es Estados Unidos. Rusia oximadamente 23 millones de gatos domésticos en 2021 n el país europeo con mayor población de este tipo de felinos. ^{6 7 8}

anico de presas potenciales, por su alta eficiencia como depredador éxito reproductivo —especialmente si se suministra artificialmente lonias sin tomar medidas adicionales para limitar su fertilidad— el está incluido en la lista de las cien especies exóticas invasoras más do do de la Unión Internacional para la Conservación de la Naturaleza.

ores comunes, como michi, 10 11 micho, 12 mizo, 13 miz, 14

Gato doméstico Estado de conservación Domesticado Taxonomía Reino: Animalia Filo: Chordata Subfilo: Vertebrata Clase: Mammalia Subclase: Theria Infraclase: Placentalia Carnivora Orden:

Feliformia

Felidae

Felinae

F. silvestris

F. s. catus

SCHREBER, 1775

Felis

Suborden:

Subfamilia: Género:

Especie:

Subespecie

Felis catus Linnaeus, 1758
 Felis silvestris domesticus

Familia:

CC-BY martingranglean.ch 2016
Data: openflights org

TRANSPORTATION CLUSTERS

3.200 airports 60.000 routes

LATIN AMERICA



Semantic Graphs

Follow Semantic standards (RDF/SPARQL) Some support properties via RDF*







ANZOGRAPH® DB



STARDOG





Property Graphs

Support labelled properties with Cypher or proprietary languages















Big Vendors with Graph Support

Support graph with proprietary database







Multi-model Graphs

Support graph with APIs on top of NoSQL DBs

























IMFD Chile

- Instituto Milenio Fundamentos de los Datos
 - Instituto de investigación interdisciplinario (Computación/Ciencias Sociales)
 - Enfocado en proyectos de gran escala
 - Uno de ellos: "Construir una base de datos de grafos"

MillenniumDB

- ¿Por qué?
 - Expertos en DB: M. Arenas, J. Reutter, C. Riveros, J. Pérez,
 D. Vrgoč
 - Semantic Web: A. Hogan, C. Gutierrez, R. Angles
 - Algorithms/compression: G. Navarro, D. Arroyuelo



MillenniumDB

- Open source
 - "Sandbox" de pruebas para algoritmos
 - Verificar hipótesis de investigación
 - Soportar Wikidata
 - Verificar si la teoría de computación vale la pena

- Involucrados
 - V. Calisto, C. Rojas (Chief Engineers)
 - B. Farías, G. Toro, ...
 - T. Hehuer, K. Bosonney, J. Romero, ...
 - D. Vrgoč, ...



MillenniumDB: Highlights

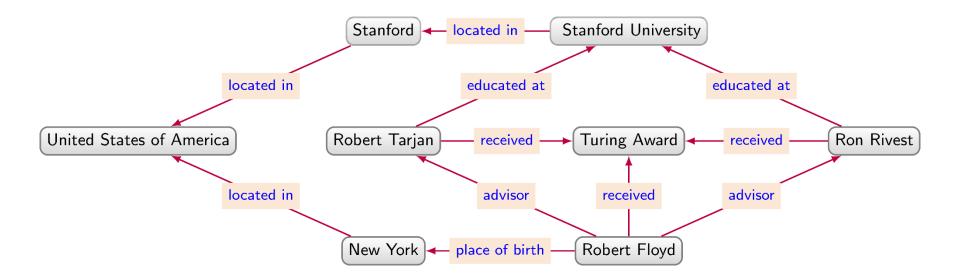
- RDF/SPARQL y Property Graph
 - Multi modelo en el mismo motor de BD
 - SPARQL extendido con features de GQL

- Pipeline clásico de BD relacional
 - "Quasi-relacional"

Arquitectura soporta endpoints públicos

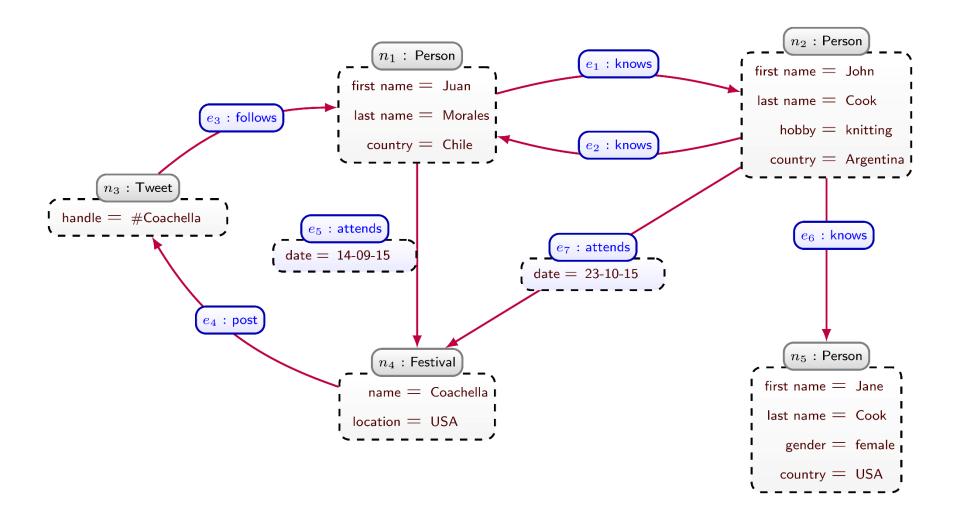


MillenniumDB: RDF





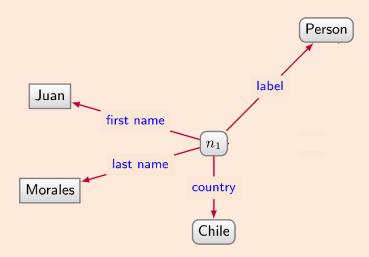
MillenniumDB: Property Graph



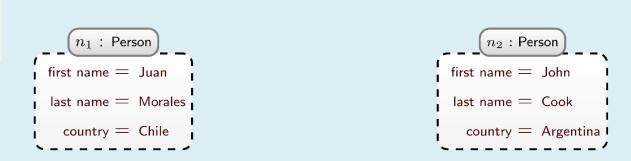


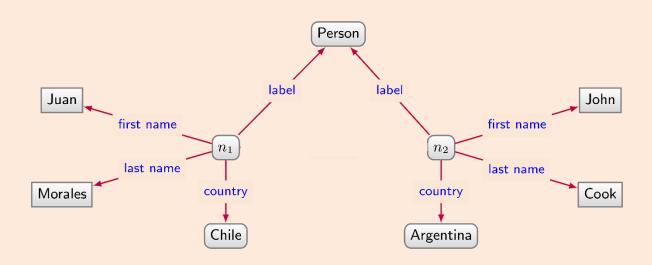
Property Graphs

```
n_1: \mathsf{Person} first name = \mathsf{Juan} last name = \mathsf{Morales} country = \mathsf{Chile}
```

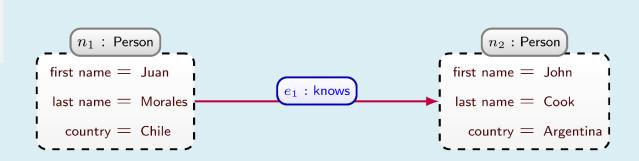


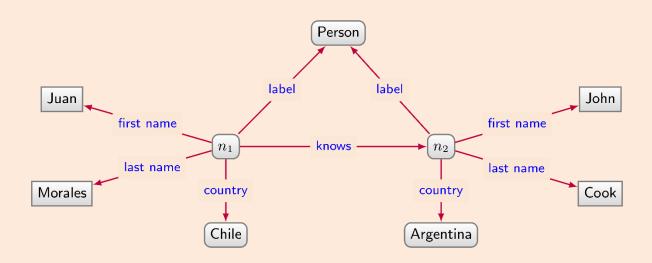
Property Graphs



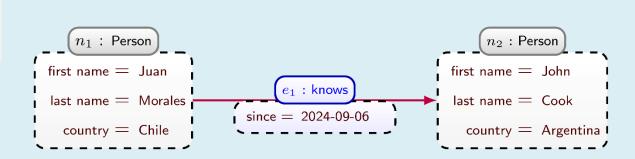


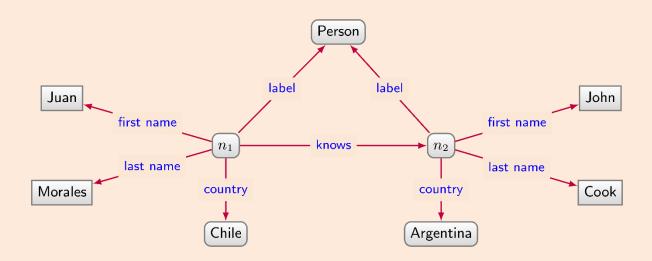
Property Graphs



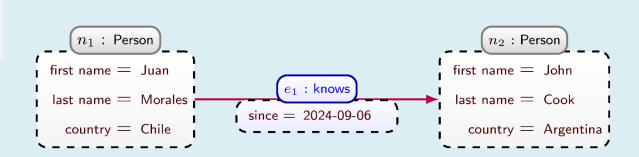


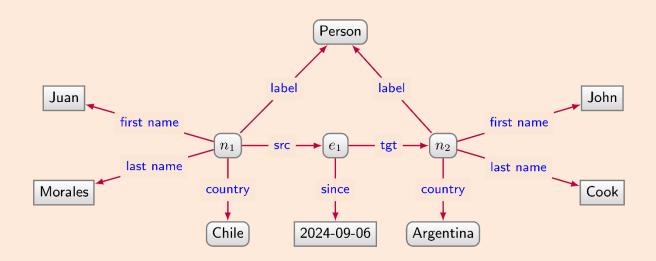
Property Graphs





Property Graphs





Wikidata: Wikipedia, pero en grafos



Main page
Community portal
Project chat
Create a new Item
Recent changes
Random Item
Query Service
Nearby
Help
Donate

Lexicographical data

Create a new Lexeme Recent changes Random Lexeme

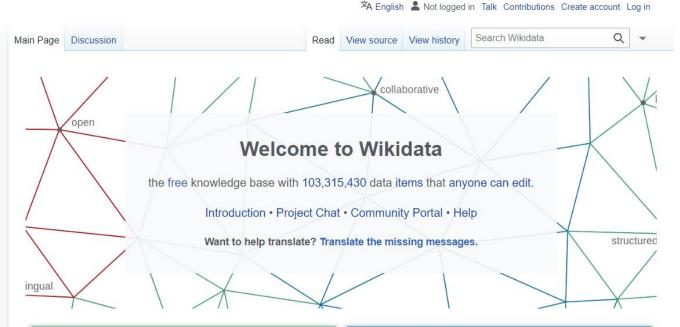
Tools

What links here Related changes Special pages Permanent link Page information Wikidata item

In other projects

Wikimania

Wikimedia Commons MediaWiki Meta-Wiki Multilingual Wikisource Wikispecies Wikibooks



Welcome!

Wikidata is a free and open knowledge base that can be read and edited by both humans and machines.

Wikidata acts as central storage for the **structured data** of its Wikimedia sister projects including Wikipedia, Wikivoyage, Wiktionary, Wikisource, and others.

Wikidata also provides support to many other sites and services beyond just Wikimedia projects! The content of Wikidata is available under a free license 2, exported using standard formats, and can be interlinked to other open data sets on the linked data web.

Learn about data

New to the wonderful world of data? Develop and improve your data literacy through content designed to get you up to speed and feeling comfortable with the fundamentals in no time.





Item: Earth (Q2)

Property: highest point (P610)



Wikidata statements

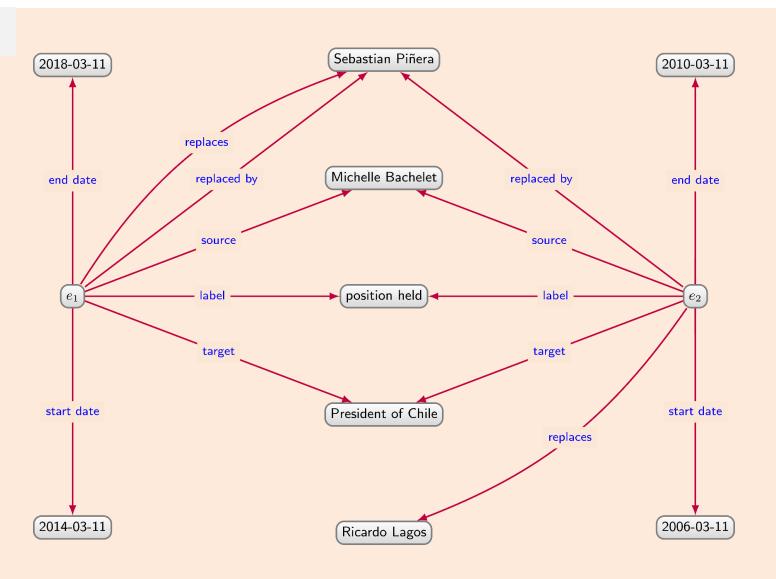
```
Michelle Bachelet [Q320]

position held [P39] President of Chile [Q466956]
start date [P580] 2014-03-11
end date [P582] 2018-03-11
replaces [P155] Sebastián Piñera [Q306]
replaced by [P156] Sebastián Piñera [Q306]

position held [P39] President of Chile [Q466956]
start date [P580] 2006-03-11
end date [P582] 2010-03-11
replaces [P155] Ricardo Lagos [Q331]
replaced by P156 Sebastián Piñera Q306
```



¿Puedo representarlo en RDF?



¿Y en Property Graph?

Property Graphs

¿Será suficiente?

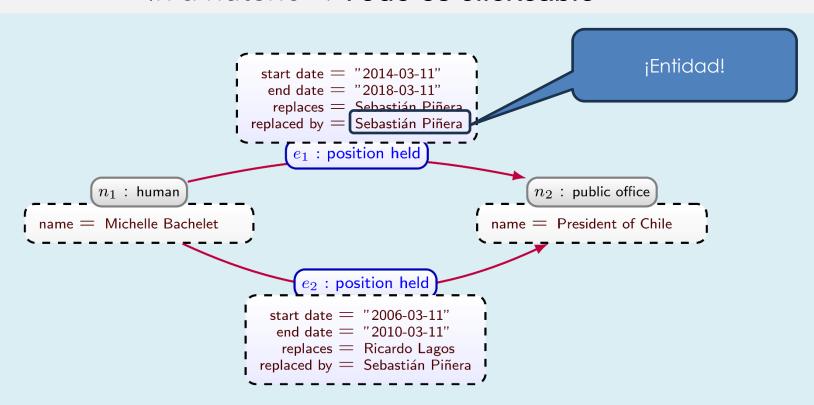
Property Graphs Clickable! start date = "2014-03-11" (DATE) end date = "2018-03-11" (DATE replaces = "Sebastián Piñera" (STRING) replaced by = "Sebastián Piñera" (STRING) e_1 : position held n_2 : public office n_1 : human name = "Michelle Bachelet" (STRING) "President of Chile" (STRING) name e_2 : position held Clickable! start date = "2006-03-11" (D_{A} end date = "2010-03-11" (DATE replaces = "Ricardo Lagos" (STRI replaced by = "Sebastián Piñera" (STRIN Clickable!

¿Será suficiente?

Property Graphs Clickable! start date = "2014-03-11" (DATE) end date = "2018-03-11" (DATE replaces = "Sebastián Piñera" (STRING) replaced by = "Sebastián Piñera" (STRING) e_1 : position held n_1 : human office n_2 : name = "Michelle Bachelet" (STRING) "Presiden ile" (STRING) e_2 : position held ¿Por qué? start date = "2006-03-11" (DATE) end date = "2010-03-11" (DATE) Quiero saber replaces = "Ricardo Lagos" (STRING) replaced by = "Sebastián Piñera" (STRING) más acerca de esa persona...

Solución: Grafos de Dominio

"In a nutshell": Todo es clickeable



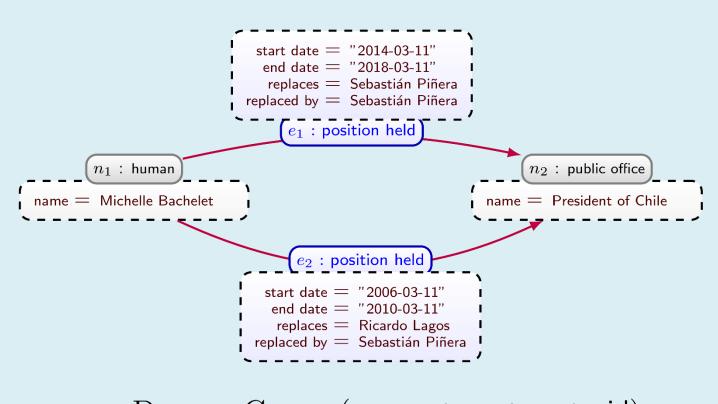
Solución: Grafos de Dominio

"In a nutshell": Todo es clickeable

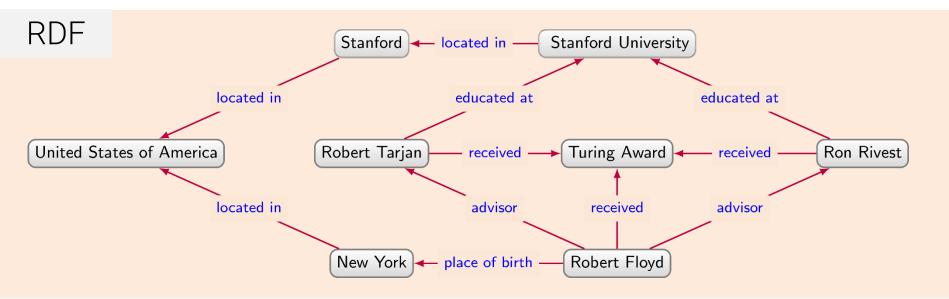
```
start date = "2014-03-11"
                           end date = "2018-03-11"
                            replaces = Sebastián Piñera
                         replaced by = Sebastián Piñera
                              e_1: position held
       n_1 : human
                                                           n_2: public office
name = Michelle Bachelet
                                                      name = President of Chile
                               e_2: position held
                           start date = "2006-03-11"
                            end date = "2010-03-11"
                             replaces = Ricardo Lagos
                          replaced by = Sebastián Piñera
           DOMAINGRAPH(source, target, eid)
           Labels (object, label)
           Properties(object, property, value)
```

Solución: Grafos de Dominio (en realidad)

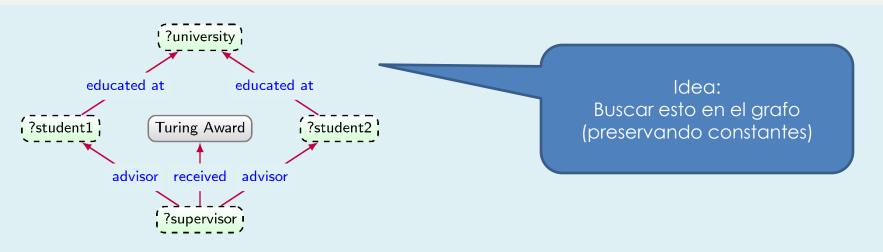
"In a nutshell": Todo es clickeable

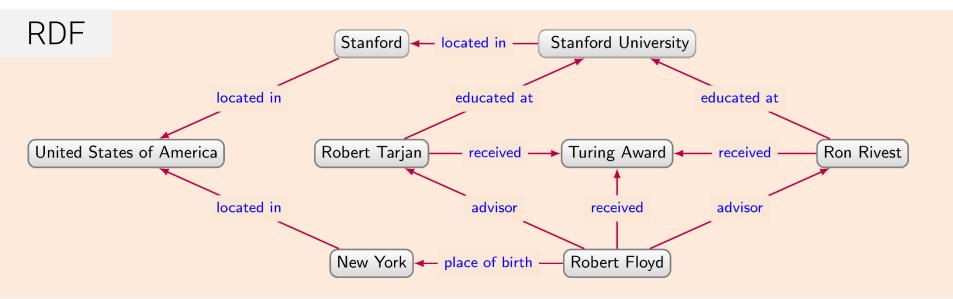


DomainGraph(source, type, target, <u>eid</u>)
Labels(object, label)
Properties(object, property, value)

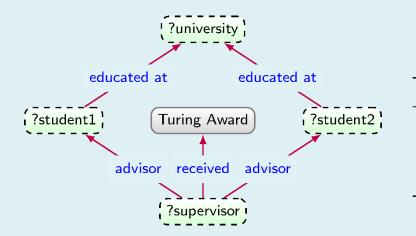


Académicos cuyo supervisor ganó el Turing Award



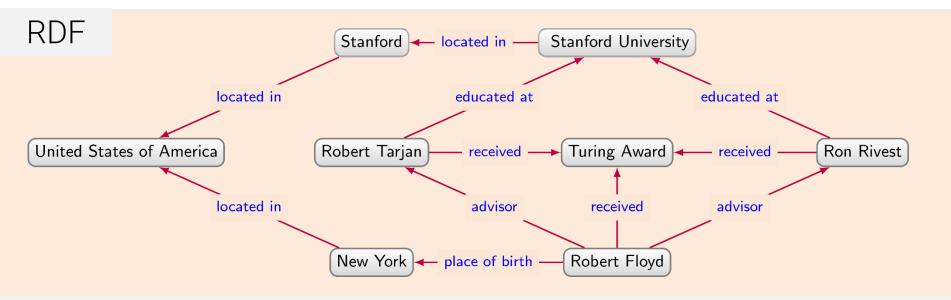


Académicos cuyo supervisor ganó el Turing Award

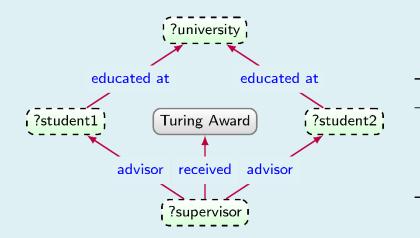


Semántica: Homomorfismo

?supervisor	?student1	?student2	?univeristy
Robert Floyd	Robert Tarjan	Ron Rivest	Stanford Univeritsy
Robert Floyd	Ron Rivest	Robert Tarjan	Stanford Univeritsy
Robert Floyd	Robert Tarjan	Robert Tarjan	Stanford Univeritsy
Robert Floyd	Ron Rivest	Ron Rivest	Stanford Univeritsy

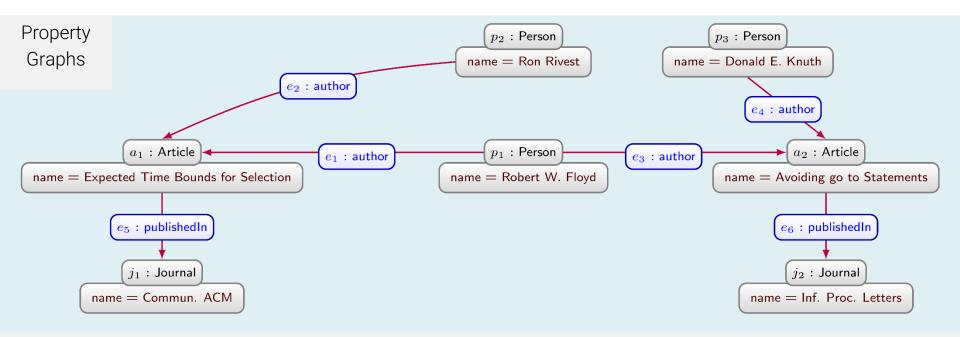


Académicos cuyo supervisor ganó el Turing Award

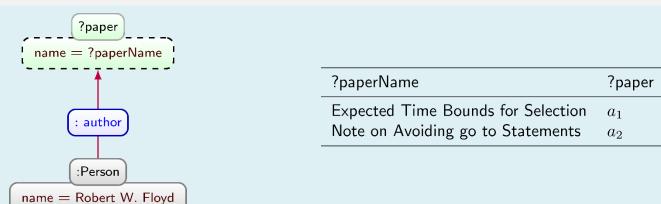


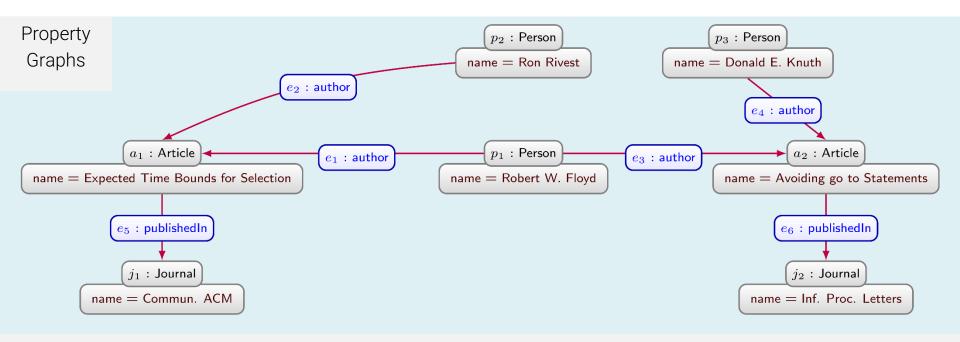
Semántica: Isomorfismo

?supervisor	?student1	?student2	?univeristy
Robert Floyd Robert Floyd	Robert Tarjan Ron Rivest	Ron Rivest Robert Tarjan	Stanford Univeritsy Stanford Univeritsy
Robert Floyd Robert Floyd	3	9	Stanford Univeritsy Stanford Univeritsy

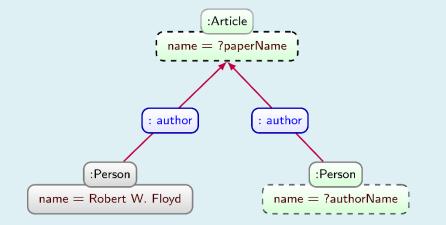


Papers escritos por Robert Floyd

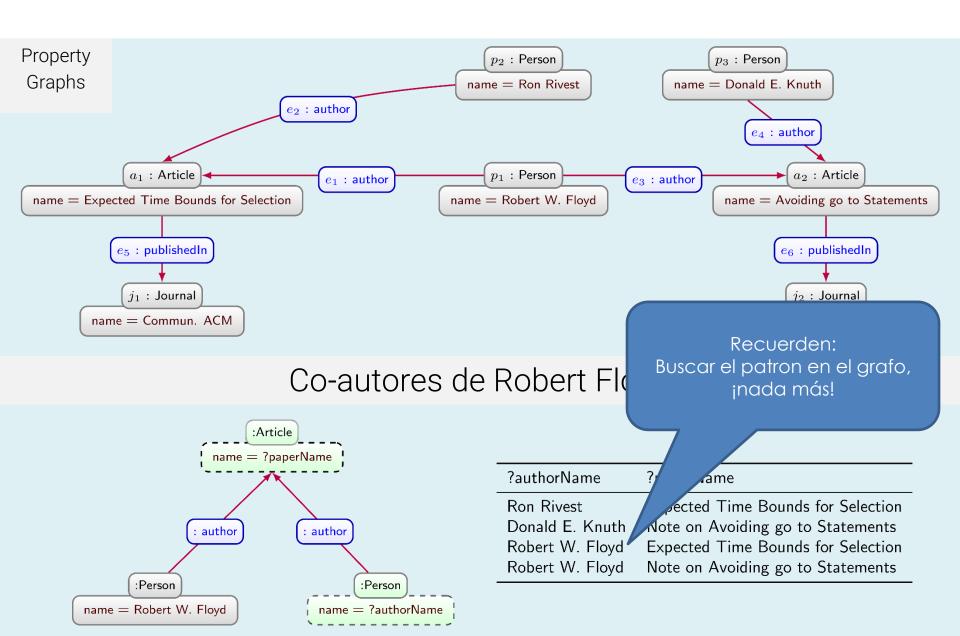




Co-autores de Robert Floyd



?authorName	?paperName		
Ron Rivest	Expected Time Bounds for Selection		
Donald E. Knuth	Note on Avoiding go to Statements		
Robert W. Floyd	Expected Time Bounds for Selection		
Robert W. Floyd	Note on Avoiding go to Statements		



¡Probemos MillenniumDB!

https://telarkg.imfd.cl/

https://bibkg.imfd.cl/



¿Qué hay disponible?

- Servidor de Base de Datos
- Interfaz Web (Alpha)
- Driver para Python (Alpha)
- Driver para JavaScript (Alpha)



MillenniumDB: Descarga y más información

Repositorio en GitHub:

https://github.com/MillenniumDB

¡Escríbanme!

vecalisto@uc.cl



¡Muchas gracias!